



ANN Introduction

বিস্তারিত বাংলা ML নোট | Intuition · Math · Code · Diagrams

📅 তৈরির তারিখ: ২০২৬-০৪-০৪ | সম্পূর্ণ বাংলায় লেখা ML Notes



Introduction to ANN (Artificial Neural Network)

Biological Neuron vs Artificial Perceptron, Layers, and Forward Propagation

বিষয়: Deep Learning-এর ভিত্তি — Artificial Neural Network

পূর্বশর্ত: Linear Regression, Logistic Regression, Gradient Descent সম্পর্কে ধারণা থাকা ভালো।

১. 🎯 সহজ ভাষায় পরিচিতি (Intuition)

এটা কী এবং কেন দরকার?

ধরো, তুমি একটি ছোট শিশু। তুমি প্রথমবার বিড়াল দেখলে চিনতে পারোনি।

কিন্তু তোমাকে ১০০০ বার বিড়াল দেখানোর পর, তুমি যেকোনো বিড়াল দেখলেই চিনে ফেলো।

তুমি এটা কীভাবে শিখলে? — তোমার **মস্তিষ্কের নিউরন** গুলো একসাথে কাজ করে এই pattern শিখেছে!

Artificial Neural Network (ANN) ঠিক এই একই কাজ করে — কিন্তু গণিত ও কম্পিউটারের মাধ্যমে।



বাস্তব জীবনের উদাহরণ:

রেস্টোরাঁর উদাহরণ:

- Input: খাবারের উপাদান (তরকারি, মসলা, পরিমাণ)
- Hidden Processing: রান্নার ধাপ

- Output: সুস্বাদু রান্না (হ্যাঁ/না)

ফুটবল খেলার উদাহরণ:

- একজন খেলোয়াড় গোল করার আগে অনেক information process করে — বলের অবস্থান, অন্য খেলোয়াড়ের দূরত্ব, গোলপোস্টের দিক।
- ANN-ও ঠিক এভাবে অনেক input একসাথে process করে সিদ্ধান্ত নেয়।

এটি কোন সমস্যা সমাধান করে?


সমস্যা	ANN-এর সমাধান
ছবি চেনা	Convolutional Neural Network
কথা বোঝা	Recurrent Neural Network
ইমেইল spam কিনা	Simple ANN Classification
ঘরের দাম বলা	Regression with ANN

Core Idea: ANN হলো মানুষের মস্তিষ্কে অনুকরণ করে বানানো একটি গাণিতিক মডেল যা data থেকে pattern খুঁজে বের করে।

২. 📖 বিস্তারিত ব্যাখ্যা (Deep Explanation)

২.১ 🧠 জৈবিক নিউরন (Biological Neuron) — আসল মস্তিষ্ক

মানুষের মস্তিষ্কে প্রায় ৮৬ বিলিয়ন নিউরন আছে! প্রতিটি নিউরনের তিনটি মূল অংশ:



প্রতিটি অংশ কী করে:


অংশ	বাংলা নাম	কাজ
Dendrites	ডেনড্রাইট	অন্য নিউরন থেকে সংকেত গ্রহণ করে
Soma (Cell Body)	কোষ দেহ	সব সংকেত একত্র করে প্রক্রিয়া করে
Axon	অ্যাক্সন	প্রক্রিয়াকৃত সংকেত পরের নিউরনে পাঠায়
Synapse	সিন্যাপস	দুই নিউরনের মাঝের সংযোগ (শক্তিশালী বা দুর্বল হতে পারে)

নিউরন কীভাবে কাজ করে:

- 1. Dendrite দিয়ে সংকেত আসে
- 2. Soma সব সংকেত যোগ করে
- 3. যদি সংকেতের যোগফল একটি threshold পার করে → Axon দিয়ে সংকেত পাঠায় ("Fire" করে)
- 4. যদি threshold না পার করে → কিছু করে না ("Don't Fire")

২.২ 🤖 কৃত্রিম নিউরন (Artificial Perceptron) — গাণিতিক নিউরন

Frank Rosenblatt ১৯৫৮ সালে প্রথম **Perceptron** তৈরি করেন — যা biological neuron-এর একটি সরল গাণিতিক রূপ।




Biological vs Artificial তুলনা:

বৈশিষ্ট্য	Biological Neuron	Artificial Perceptron
Input গ্রহণ	Dendrites — বৈদ্যুতিক সংকেত	Input values ($x_1, x_2, \dots, x_n$) — সংখ্যা
সংযোগের শক্তি	Synapse — শক্তিশালী/দুর্বল	Weights (w) — বড়/ছোট সংখ্যা
Processing	Soma — সব সংকেত যোগ করে	Weighted Sum: $\Sigma(w_i x_i) + b$
Output সিদ্ধান্ত	Threshold পার হলে "Fire" করে	Activation Function $f(z)$
Output পাঠানো	Axon — পরের নিউরনে	সংখ্যা — পরের layer/output এ
শেখার পদ্ধতি	Neuroplasticity	Backpropagation (Gradient Descent)
গতি	০.০০১-১০০ Hz	কোটি operations/second

২.৩ 🧠 Neural Network-এর Layer সমূহ

একটি সম্পূর্ণ ANN-এ তিন ধরনের Layer থাকে:



● Input Layer (ইনপুট লেয়ার)

কী করে: Raw data গ্রহণ করে।

বিশেষত্ব: এখানে কোনো calculation হয় না, শুধু data ধরে রাখে।

নিউরন সংখ্যা: = Feature-এর সংখ্যা

উদাহরণ:

- বাড়ির দাম বলার জন্য: rooms, area, location, age → **৪টি input নিউরন**
- ছবি চেনার জন্য 28×28 pixel: → **784টি input নিউরন**

বাড়ির দাম predict করা:

Input Layer:

- x_1 = কতটি রুম আছে (যেমন: 3)
- x_2 = আয়তন (যেমন: 1500 sq ft)
- x_3 = অবস্থান (1=শহর, 0=গ্রাম)
- x_4 = বয়স (যেমন: 10 বছর)

● Hidden Layer(s) (হিডেন লেয়ার)

কী করে: Input থেকে complex pattern ও features শেখে।

কেন "Hidden": User এর কাছে সরাসরি দেখা যায় না, ভেতরে ভেতরে কাজ করে।

নিউরন ও লেয়ার সংখ্যা: সমস্যার জটিলতার উপর নির্ভর করে।

Depth এবং Width:

- Width (প্রস্থ):** এক লেয়ারে কতটি নিউরন

- **Depth (গভীরতা):** মোট কতটি hidden layer

বাস্তব উদাহরণ (মুখ চেনা):

Layer 1: Basic edges শেখে (আনুভূমিক, উল্লম্ব রেখা)

Layer 2: চোখ, নাক, মুখ recognise করে

Layer 3: সম্পূর্ণ মুখ চেনে

জরুরি তথ্য: Hidden layer-এর নিউরনগুলো কেউ বলে দেয় না কী শিখবে। Training-এর মাধ্যমে নিজেই শেখে!

● **Output Layer (আউটপুট লেয়ার)**

কী করে: Final prediction দেয়।

নিউরন সংখ্যা: সমস্যার ধরনের উপর নির্ভর করে।

সমস্যার ধরন	Output নিউরন	Activation Function	উদাহরণ
Binary Classification	১টি	Sigmoid (0-1)	Email spam কিনা
Multi-class Classification	N টি (N=class সংখ্যা)	Softmax	বিড়াল/কুকুর/পাখি
Regression	১টি	Linear (None)	বাড়ির দাম

২.8 ⚡ **Forward Propagation (ফরওয়ার্ড প্রপাগেশন)**

Forward Propagation হলো ANN-এর "prediction করার" প্রক্রিয়া।

Data Input Layer → Hidden Layer(s) → Output Layer পর্যন্ত এগিয়ে যাওয়াকেই Forward Propagation বলে।

ধাপে ধাপে প্রক্রিয়া (প্রতিটি layer-এ):

ধাপ ১: প্রতিটি input কে তার weight দিয়ে গুণ করো

$$w_1 \times x_1, w_2 \times x_2, w_3 \times x_3 \dots$$

ধাপ ২: সবগুলো যোগ করো এবং bias যোগ করো

$$z = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

ধাপ ৩: Activation Function প্রয়োগ করো

$$a = f(z) \quad [\text{যেমন: ReLU, Sigmoid}]$$

ধাপ ৪: এই output পরের layer-এর input হয়

এই 'a' পরের layer-এর x হিসেবে যায়

৩. Math / Theory

৩.১ Single Perceptron-এর Math

একটি Perceptron-এ n টি input আছে — $x_1, x_2, \dots, x_n$ । প্রতিটির একটি weight আছে — $w_1, w_2, \dots, w_n$ ।

Step 1: Weighted Sum (z)

$$z = \sum_{i=1}^n w_i x_i + b = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

Symbol অর্থ:

- x_i = i-তম input feature
- w_i = i-তম weight (গুরুত্ব)
- b = bias (মডেলকে shift করে)
- z = weighted sum (pre-activation value)

Step 2: Activation Function (a)

$$a = f(z)$$

সাধারণ Activation Functions:

- Sigmoid:** $f(z) = \frac{1}{1+e^{-z}}$ → output: 0 থেকে 1
- ReLU:** $f(z) = \max(0, z)$ → output: 0 বা positive
- Tanh:** $f(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$ → output: -1 থেকে 1

৩.২ Multi-layer ANN-এর Matrix Form

যখন অনেক নিউরন একসাথে থাকে, তখন Matrix ব্যবহার করা হয়:

Layer l-এর জন্য:

$$z^{(l)} = W^{(l)} \cdot a^{(l-1)} + b^{(l)}$$

$$a^{(l)} = f(z^{(l)})$$

Symbol অর্থ:

- $W^{(1)}$ = l-তম layer-এর Weight Matrix
- $a^{(l-1)}$ = (l-1)-তম layer-এর output (পূর্ববর্তী layer)
- $b^{(1)}$ = l-তম layer-এর Bias vector
- $z^{(1)}$ = l-তম layer-এর pre-activation values
- $a^{(1)}$ = l-তম layer-এর activation output
- $a^{(0)}$ = x = Input layer (প্রথম layer)

৩.৩ Manual Calculation (সহজ উদাহরণ)

ধরো, একটি ছাত্র পরীক্ষায় পাস করবে কিনা predict করবো।

Input:

- x_1 = পড়াশোনার সময় (ঘণ্টা) = 5
- x_2 = ঘুমের সময় (ঘণ্টা) = 7

Weights (ধরে নেওয়া):

- $w_1 = 0.5$ (পড়া বেশি গুরুত্বপূর্ণ)
- $w_2 = 0.3$
- $b = -2$ (bias)

Calculation:

$$z = w_1 \times x_1 + w_2 \times x_2 + b$$
$$z = 0.5 \times 5 + 0.3 \times 7 + (-2)$$
$$z = 2.5 + 2.1 - 2$$
$$z = 2.6$$

Sigmoid activation:

$$a = 1 / (1 + e^{(-2.6)})$$
$$a = 1 / (1 + 0.074)$$
$$a = 1 / 1.074$$
$$a \approx 0.931$$

ব্যাখ্যা: 93.1% সম্ভাবনা → ছাত্রটি পাস করবে! ✓

৩.৪ Multi-layer Calculation (2-Layer Network)

Network: Input(2) → Hidden(3) → Output(1)

INPUT: $x = [5, 7]^T$

--- HIDDEN LAYER ---

$W^1 = \begin{bmatrix} 0.5 & 0.3 \\ 0.2 & 0.8 \\ 0.4 & 0.1 \end{bmatrix}, \quad b^1 = \begin{bmatrix} 0.1 \\ 0.2 \\ 0.3 \end{bmatrix}$

$z^1 = W^1 \cdot x + b^1$

$z^1[0] = 0.5 \times 5 + 0.3 \times 7 + 0.1 = 2.5 + 2.1 + 0.1 = 4.7$

$z^1[1] = 0.2 \times 5 + 0.8 \times 7 + 0.2 = 1.0 + 5.6 + 0.2 = 6.8$

$z^1[2] = 0.4 \times 5 + 0.1 \times 7 + 0.3 = 2.0 + 0.7 + 0.3 = 3.0$

$a^1 = \text{ReLU}(z^1) = [4.7, 6.8, 3.0]$ (সব positive, তাই একই থাকে)

--- OUTPUT LAYER ---

$W^2 = [0.6, 0.4, 0.5], \quad b^2 = [-1]$

$z^2 = W^2 \cdot a^1 + b^2$

$z^2 = 0.6 \times 4.7 + 0.4 \times 6.8 + 0.5 \times 3.0 + (-1)$

$z^2 = 2.82 + 2.72 + 1.5 - 1$

$z^2 = 6.04$

$a^2 = \text{Sigmoid}(6.04) = 1/(1+e^{(-6.04)}) \approx 0.9976$

ফলাফল: 99.76% → পাস! 🎉

8. Code Example (Python)

```

# ===== IMPORTS =====
import numpy as np          # সংখ্যা গণনার জন্য
import matplotlib.pyplot as plt  # গ্রাফ আঁকার জন্য

# ===== ACTIVATION FUNCTIONS =====

def sigmoid(z):
    """Sigmoid activation function: output 0 থেকে 1 এর মধ্যে"""
    return 1 / (1 + np.exp(-z))

def relu(z):
    """ReLU activation function: negative হলে 0, positive থাকলে অপরিবর্তিত"""
    return np.maximum(0, z)

def softmax(z):
    """Softmax: multi-class classification এর জন্য, সব output এর যোগফল = 1"""
    exp_z = np.exp(z - np.max(z))  # numerical stability র জন্য max বিয়োগ করা হয়
    return exp_z / exp_z.sum()

# ===== ANN CLASS =====

class SimpleANN:
    """
    একটি সহজ Artificial Neural Network
    Architecture: Input → Hidden → Output
    """

    def __init__(self, input_size, hidden_size, output_size):
        """
        নেটওয়ার্ক initialize করা

        Parameters:
            input_size : কতটি feature আছে (input নিউরন)
            hidden_size : hidden layer-এ কতটি নিউরন
            output_size : output layer-এ কতটি নিউরন
        """
        print(f"🌸 ANN তৈরি হচ্ছে: {input_size} → {hidden_size} → {output_size}")

# ===== WEIGHTS এবং BIASES INITIALIZE =====
# Random ছোট সংখ্যা দিয়ে শুরু করা হয়
# 0.01 দিয়ে গুণ করা হয় যাতে শুরুতে খুব বড় না হয়

```

```

# Hidden Layer weights: shape = (hidden_size, input_size)
self.W1 = np.random.randn(hidden_size, input_size) * 0.01
# Hidden Layer bias: shape = (hidden_size, 1)
self.b1 = np.zeros((hidden_size, 1))

# Output Layer weights: shape = (output_size, hidden_size)
self.W2 = np.random.randn(output_size, hidden_size) * 0.01
# Output Layer bias: shape = (output_size, 1)
self.b2 = np.zeros((output_size, 1))

print(f"    W1 এর shape: {self.W1.shape}")
print(f"    W2 এর shape: {self.W2.shape}")

def forward_propagation(self, X):
    """
    Forward Propagation – input থেকে output পর্যন্ত যাওয়া

    Parameters:
        X : Input data, shape = (input_size, samples)

    Returns:
        output : Final prediction
    """
    print("\n🔵 Forward Propagation শুরু...")

    # ===== HIDDEN LAYER =====
    # Step 1: Weighted sum = W1 dot X + b1
    self.z1 = np.dot(self.W1, X) + self.b1
    print(f"    Hidden z1 (weighted sum): shape = {self.z1.shape}")

    # Step 2: Activation function প্রয়োগ (ReLU)
    self.a1 = relu(self.z1)
    print(f"    Hidden a1 (after ReLU): shape = {self.a1.shape}")

    # ===== OUTPUT LAYER =====
    # Step 3: Weighted sum = W2 dot a1 + b2
    self.z2 = np.dot(self.W2, self.a1) + self.b2
    print(f"    Output z2 (weighted sum): shape = {self.z2.shape}")

    # Step 4: Activation function (Sigmoid – binary classification)
    self.a2 = sigmoid(self.z2)
    print(f"    Output a2 (after Sigmoid): shape = {self.a2.shape}")

```

```

        return self.a2

    def predict(self, X):
        """
        Prediction করা - 0.5 এর বেশি হলে 1 (পাস), কম হলে 0 (ফেল)
        """
        output = self.forward_propagation(X)
        return (output >= 0.5).astype(int)

# ===== MAIN: ব্যবহার করা =====

print("=" * 60)
print("🎓 ছাত্রের পরীক্ষার ফলাফল predict করা")
print("=" * 60)

# ডেটা তৈরি করা (3 জন ছাত্র)
# Feature 1: পড়াশোনার সময় (ঘণ্টা)
# Feature 2: ঘুমের সময় (ঘণ্টা)
# প্রতিটি column = এক জন ছাত্র
X = np.array([
    [5, 2, 8],    # পড়াশোনার সময়
    [7, 4, 6]     # ঘুমের সময়
], dtype=float)

print(f"\n🇬🇧 Input Data (3 জন ছাত্র):")
print(f"    পড়াশোনার সময়: {X[0]}")
print(f"    ঘুমের সময়:      {X[1]}")

# ANN তৈরি করা: 2 input, 3 hidden, 1 output
ann = SimpleANN(input_size=2, hidden_size=3, output_size=1)

# Forward Propagation চালানো
output = ann.forward_propagation(X)

print(f"\n✅ Output (0-1 এর মধ্যে সম্ভাবনা):")
for i in range(X.shape[1]):
    prob = output[0][i]
    result = "পাস ✅" if prob >= 0.5 else "ফেল ❌"
    print(f"    ছাত্র {i+1}: {prob:.4f} ({prob*100:.1f}%) → {result}")

# ===== LAYER VISUALIZATION =====

def visualize_network():

```

```

"""Neural Network-এর একটি simple visualization"""
fig, ax = plt.subplots(1, 1, figsize=(10, 6))
ax.set_xlim(0, 10)
ax.set_ylim(0, 10)
ax.axis('off')
ax.set_title('Simple ANN Architecture: 2→3→1',
             fontsize=14, fontweight='bold', pad=20)

# Layer positions (x coordinates)
layers = {
    'Input\nLayer': (1.5, [3, 7]),          # 2 নিউরন
    'Hidden\nLayer': (5, [2, 4, 6, 8]),      # 4 নিউরন (visualization)
    'Output\nLayer': (8.5, [5])              # 1 নিউরন
}

colors = {'Input\nLayer': '#3498DB',
          'Hidden\nLayer': '#F39C12',
          'Output\nLayer': '#2ECC71'}

node_positions = {}

# নিউরন আঁকা
for layer_name, (x, ys) in layers.items():
    node_positions[layer_name] = [(x, y) for y in ys]
    for y in ys:
        circle = plt.Circle((x, y), 0.4,
                             color=colors[layer_name],
                             ec='black', linewidth=1.5, zorder=3)
        ax.add_patch(circle)

# Layer নাম
ax.text(x, 0.5, layer_name, ha='center', va='center',
        fontsize=9, fontweight='bold', color=colors[layer_name])

# Connections আঁকা
for i, ((l1_name, (x1, ys1)), (l2_name, (x2, ys2))) in enumerate(
    zip(list(layers.items())[:-1], list(layers.items())[1:])):
    for y1 in ys1:
        for y2 in ys2:
            ax.plot([x1 + 0.4, x2 - 0.4], [y1, y2],
                    'gray', linewidth=0.5, alpha=0.5, zorder=1)

# Labels

```

```

ax.text(1.5, 9.2, 'x1, x2\n(Features)', ha='center', fontsize=8)
ax.text(5, 9.2, 'ReLU\nActivation', ha='center', fontsize=8)
ax.text(8.5, 9.2, 'Sigmoid\n(0-1)', ha='center', fontsize=8)

plt.tight_layout()
plt.savefig('ann_visualization.png', dpi=150, bbox_inches='tight')
plt.show()
print("\n📊 Graph সেভ হয়েছে: ann_visualization.png")

# Graph তৈরি করা
visualize_network()

```

Expected Output:

=====

🎓 ছাত্রের পরীক্ষার ফলাফল predict করা

=====

📊 Input Data (3 জন ছাত্র):

পড়াশোনার সময়: [5. 2. 8.]

ঘুমের সময়: [7. 4. 6.]

🧠 ANN তৈরি হচ্ছে: 2 → 3 → 1

W1 এর shape: (3, 2)

W2 এর shape: (1, 3)

🔍 Forward Propagation শুরু...

Hidden z1 (weighted sum): shape = (3, 3)

Hidden a1 (after ReLU): shape = (3, 3)

Output z2 (weighted sum): shape = (1, 3)

Output a2 (after Sigmoid): shape = (1, 3)

✅ Output (0-1 এর মধ্যে সম্ভাবনা):

ছাত্র ১: 0.5021 (50.2%) → পাস ✅

ছাত্র ২: 0.4998 (49.9%) → ফেল ❌


ছাত্র ৩: 0.5034 (50.3%) → পাস ✅

(Note: weights random তাই output ভিন্ন হতে পারে। Training ছাড়া ANN ভালো predict করতে পারে না!)


🔗 🎨 Visual / Diagram

🔗.১ Biological Neuron vs Artificial Perceptron


BIOLOGICAL NEURON:




ARTIFICIAL PERCEPTRON:



🔗.২ Full ANN Architecture



Forward Propagation Flow



4.8 Weight Matrix Shape

Input(3) → Hidden(4) → Output(2) Network:

W^1 Shape: (4, 3)

$$\begin{bmatrix} | & w_{11} & w_{12} & w_{13} & | \\ | & w_{21} & w_{22} & w_{23} & | \\ | & w_{31} & w_{32} & w_{33} & | \\ | & w_{41} & w_{42} & w_{43} & | \end{bmatrix}$$

[4×3 matrix]

W^2 Shape: (2, 4)

$$\begin{bmatrix} | & w_{11} & w_{12} & | \\ | & w_{13} & w_{14} & | \\ | & w_{21} & w_{22} & | \\ | & w_{23} & w_{24} & | \end{bmatrix}$$

[2×4 matrix]

Rule: W shape = (current_layer_neurons, previous_layer_neurons)

৬. Real-world Use Cases

১. Email Spam Detection (Google Gmail)

- **Input:** Email-এর শব্দ, লিংক সংখ্যা, sender info
- **ANN Output:** Spam (1) বা Not Spam (0)
- **Company:** Google — ১৫ বিলিয়নেরও বেশি Gmail user এর সুরক্ষায়

২. Stock Price Prediction (Bloomberg, Hedge Funds)

- **Input:** আগের দামের ইতিহাস, trading volume, market news sentiment
- **ANN Output:** পরের দিনের price
- **Use:** Renaissance Technologies, Two Sigma এর মতো hedge fund

৩. Medical Diagnosis (IBM Watson Health)

- **Input:** রোগীর symptoms, blood test result, age, weight
- **ANN Output:** রোগের সম্ভাবনা (%)
- **Use Case:** Cancer early detection, Diabetic prediction

৪. Speech Recognition (Apple Siri, Google Assistant)

- **Input:** শব্দের audio waveform

- **ANN Output:** Text transcription
- **Company:** Apple, Google, Amazon Alexa

৫. 🎮 Game Playing (DeepMind)

- **Input:** Game-এর current state (screen pixels বা board position)
- **ANN Output:** কোন move করবে
- **Achievement:** AlphaGo — বিশ্ব চ্যাম্পিয়নকে হারিয়েছে

৭. ⚖️ Pros & Cons

সুবিধা ✅	অসুবিধা ❌
Complex, nonlinear pattern শিখতে পারে	প্রচুর data দরকার (কম data = খারাপ result)
Image, text, audio সব ধরনের data handle করে	Training-এ অনেক সময় ও computation লাগে
Feature engineering কম লাগে, নিজেই শেখে	"Black box" — বোঝা কঠিন কেন prediction দিলো
Scalable — বড় network বানানো সম্ভব	Hyperparameter tuning অনেক কঠিন
Human-level বা তার বেশি accuracy পেতে পারে	Overfitting-এর সম্ভাবনা বেশি
Transfer Learning সম্ভব	GPU/TPU ছাড়া train করা slow
Parallel computation efficient	Architecture design করা জটিল

৮. ⚠️ Common Mistakes & Gotchas

ভুল ১: Data Normalization না করা

```
# ❌ ভুল: Raw data সরাসরি দেওয়া
X = [[1500, 3, 10]] # [area=1500, rooms=3, age=10]
# সমস্যা: 1500 এর weight gradient অনেক বড়, 3 এর gradient ছোট

# ✅ সঠিক: Normalize করা
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_normalized = scaler.fit_transform(X)
```

ভুল ২: Activation Function ভুল জায়গায় ব্যবহার

```
# ❌ ভুল: Hidden layer-e Sigmoid ব্যবহার
# Sigmoid: gradient vanishing সমস্যা হয়

# ✅ সঠিক: Hidden layer-e ReLU ব্যবহার করা
# Output layer: task অনুযায়ী (Binary → Sigmoid, Multi-class → Softmax)
```

ভুল ৩: Weight শূন্য দিয়ে initialize করা

```
# ❌ ভুল: সব weight = 0
W = np.zeros((hidden, input))
# সমস্যা: সব নিউরন একই জিনিস শিখবে (symmetry problem)

# ✅ সঠিক: Random small values
W = np.random.randn(hidden, input) * 0.01
```

ভুল ৪: Network অনেক Deep করা (কম data নিয়ে)

```
Data: 1000 samples
Network: 100 → 1000 → 1000 → 1000 → 1 ← ❌ Overfitting হবে!
Better: 100 → 64 → 32 → 1 ← ✅
```

ভুল ৫: Bias ভুলে যাওয়া

❌ ভুল: Bias ছাড়া

$z = W @ X$ # Bias নেই!

✅ সঠিক: Bias সহ

$z = W @ X + b$ # b ছাড়া model যথেষ্ট flexible নয়

ভুল ৬: Learning Rate ভুল রাখা

Learning Rate অনেক বড়: Loss diverge করে (বাড়তে থাকে)

Learning Rate অনেক ছোট: Training অনেক slow

ভালো শুরু: 0.001 বা 0.01 দিয়ে শুরু করে

৯. 📌 Related Topics

আগে জানা দরকার (Prerequisites):

1. **Linear Regression** — weighted sum এবং prediction বোঝার জন্য
2. **Logistic Regression** — Sigmoid function এবং binary classification
3. **Gradient Descent** — ANN কীভাবে weights update করে তা বোঝার জন্য
4. **NumPy Basics** — Matrix multiplication এর জন্য
5. **Calculus (Chain Rule)** — Backpropagation বোঝার জন্য

এরপর কী শেখা উচিত:

1. **Activation Functions** — ReLU, Tanh, Softmax-এর বিস্তারিত
2. **Backpropagation** — ANN কীভাবে weights শেখে
3. **Overfitting ও Regularization** — Dropout, L1/L2
4. **CNN (Convolutional Neural Network)** — Image processing
5. **Keras/PyTorch দিয়ে ANN** — Production-level implementation

১০. 🗨️ Memory Tricks

মনে রাখার সহজ কৌশল:

১. ANN = পেঁয়াজ

পেঁয়াজের মতো ANN-এ অনেক Layer:

বাইরের Layer → ভেতরের Layer → কেন্দ্র

Input Layer → Hidden Layers → Output Layer

২. Forward Propagation = পানির স্রোত

পাহাড় থেকে পানি নামে:

ওপর (Input) → মাঝামাঝি (Hidden) → নিচে (Output)

একবার নামলে আর পেছনে যায় না (Forward মানে সামনে!)

৩. Weight = শিক্ষকের গুরুত্ব

তুমি যদি ৩ জন শিক্ষকের কাছে পড়ো:

- Physics Teacher (weight=0.7): বেশি গুরুত্বপূর্ণ
- Math Teacher (weight=0.5): মাঝামাঝি
- Bangla Teacher (weight=0.2): কম গুরুত্বপূর্ণ

ANN-ও ঠিক এভাবে input-দের weight দেয়!

৪. Activation Function = স্কুলের গেট

সিকিউরিটি গার্ড (Activation Function):

সংকেত যদি থ্রেশহোল্ড পার করে → গেট খুলে দেয় (আউটপুট দেয়)

না করলে → গেট বন্ধ রাখে (কোনো আউটপুট নেই)

📌 এক লাইনে সারসংক্ষেপ:

"ANN হলো মানুষের মস্তিষ্কের গাণিতিক রূপ, যা Input data নিয়ে পর্যায়ক্রমে weighted sum এবং activation function প্রয়োগ করে (Forward Propagation) একটি intelligent prediction তৈরি করে।"

🔑 Key Formulas চিটশিট:

Single Neuron:

$$z = \sum (w_i \times x_i) + b$$

$$a = f(z)$$

Layer Calculation (Matrix Form):

$$z^{(1)} = W^{(1)} \cdot a^{(1-1)} + b^{(1)}$$

$$a^{(1)} = f(z^{(1)})$$

Common Activations:

Sigmoid: $1/(1+e^{-z})$ → 0 to 1

ReLU: $\max(0, z)$ → 0 or positive

Softmax: $e^{z^i} / \sum e^{z^j}$ → sums to 1

📅 তৈরির তারিখ: ২০২৬-০৪-০৪

📖 পর্ব: Deep Learning Foundations — ANN Series (Part 1/3)

🔊 পরবর্তী: Activation Functions in Neural Networks

📖 Machine Learning & Deep Learning Notes — সম্পূর্ণ বাংলায়

🤖 AI-assisted Bengali ML Notes | D:\Coding\Generative-AI\ML_Notes